

技术报告

Apple Silicon 上本地 LLM 推理服务器 的自愈看门狗

oMLX 故障模式与有界恢复的实证研究

ricky8848

独立研究员

报告编号: TR-2026-09-ZH

日期: 2026 年 9 月

许可证: MIT

代码仓库: <https://github.com/ricky8848/omlx-watchdog> (v6.1)

配套配置: <https://github.com/ricky8848/mac-m5-128g-omlx-settings>

摘要

Apple Silicon 上的本地大语言模型 (LLM) 推理服务器越来越多地作为自主编码智能体的后端，但它们运行在任何编排器之外：没有 Kubernetes 存活探针、没有 systemd 重启策略——更关键的是，故障模式是部分性的（进程存活但引擎卡死）。我们对一台这样的服务器进行了实证研究：oMLX 在 Apple M5 Max (128GB) 上服务 Qwen3.8-27B，连续 13 天、共 18,516 次看门狗心跳。我们形式化了六种故障类别（引擎卡死、端口占用者、SIGKILL/OOM、陈旧注册表、预填充内存保护拒绝、客户端重试放大），并提出了一个无自干扰的健康模型：四个互补检查的谓词互不冲突，驱动有界升级阶梯（`omlx restart` → 仅监听者端口清理 + 30 秒宽限 → GUI 重启）。在生产环境中，看门狗在一个 60 秒心跳内检测到所有引擎故障，并在四分钟内恢复服务且无需人工干预；部署后主导的故障类别（模型切换后的陈旧注册表）通过版本化修复被消除。我们讨论了后端自愈与客户端有界重试的正交性，以及投机解码吞吐量（MTP 接受率 85–96%）与可用性的独立但乘积关系。

关键词：本地 LLM 推理、自愈系统、Apple Silicon、看门狗、故障分类学、有界升级

目录

1 引言	2
2 系统架构	2
3 故障分类学	2
4 检测：无自干扰健康模型	3
5 恢复：有界升级阶梯	3
6 评估：13 天生产数据	4
7 相关工作	4
8 效度威胁	5
9 结论	5




图 1: 三层防御: launchd 心跳 → 看门狗谓词评估 → 有界升级阶梯, 客户端重试预算跨越重启窗口。

1 引言

自主编码智能体 (DeepSeek Harness、Codex CLI、OpenClaw/Hermes 网关) 向本地 LLM 服务器发起长时程工具调用工作负载。在 Apple Silicon 上, oMLX 通过 Metal/ANE 提供 OpenAI 兼容 API, 支持多 token 预测 (MTP)。与云部署不同, 本地服务器没有编排器: 卡死的引擎 (进程存活、token 冻结) 对 ps 不可见, 而朴素的”日志 mtime = 忙碌”存活探针在取消请求写入自身日志行时会自干扰。

本文贡献:

- 在 13 天生产跟踪中观察到的六种故障类别分类学 (第 3 节)。
- 四个检查谓词互不冲突的无自干扰健康模型 (第 4 节)。
- 带形式化端口清理安全论证的有界升级阶梯 (第 5 节)。
- 生产评估: 18,516 次心跳下 $MTTD \leq 60s$ 、 $MTTR < 4min$ (第 6 节)。
- 结合服务器侧看门狗、客户端有界重试 ($N=40$)、launchd 双重守护的三层防御体系 (第 2 节)。

2 系统架构

图 1 展示了三层防御体系。第 1 层 (launchd) 提供粗粒度 $StartInterval=60$ 心跳。第 2 层 (看门狗脚本) 评估四个谓词并通过有界阶梯升级。第 3 层 (客户端重试预算) 确保在途请求跨越重启窗口而不放大负载。

3 故障分类学

表 1 列出了六种故障类别及其生产发生率。图 2 展示了故障类别与恢复动作之间的因果关系。

类别	机制	发生率 (13 天)
F1 引擎卡死	Metal 层卡住；请求被接受但无 token	2 次事件 (9 月 8 日)
F2 端口占用者	重启后:8000 上陈旧监听；重试旋转	26 次端口清理
F3 SIGKILL/OOM	系统杀死；launchd 不自动重启 GUI 应用	96 次回退
F4 陈旧注册表	<code>loaded_models</code> 在模型切换后不同步	79 次恢复 (v5 时代)
F5 预填充保护拒绝	内存上限处的可预测 HTTP 400 (设计使然)	n/a
F6 客户端重试放大	<code>mode:always</code> 重试 $\times$ 重启窗口 = 死亡循环 (修复前)	1 次事件

表 1: 故障类别与生产发生率 (9 月 27 日 – 9 月 9 日, 18,516 次心跳)。F4 主导 v5 时代, 通过 v6 的空注册表感知检查 B 被消除。

F1/F3 的区分很重要: `oMLX restart` 修复卡死, 但被占用的端口使重启本身失败, 产生 F2 旋转——这正是仅监听者清理的动机。

4 检测：无自干扰健康模型

看门狗心跳 t 评估服务器状态的四个谓词：

$$A(t) : \text{api/status 在 5s 内可达} \quad (1)$$

$$B(t) : (\text{loaded_models} = \emptyset) \vee (\exists m: m.\text{registered}) \quad (2)$$

$$C(t) : \neg \text{busy}(t) \vee \text{IDLEPROBE}(\text{max_tokens} = 4) = \text{OK} \quad (3)$$

$$D(t) : \neg (\text{workInFlight}(t) \wedge \Delta t_{\text{token}}(t) \geq 900 \text{ s}) \quad (4)$$

其中 $\text{busy}(t)$ 是服务器自身的队列计数器 (`active+waiting>0`)。健康谓词为 $H(t) = A \wedge B \wedge C \wedge D$ 。**无自干扰性**。检查 C 仅在队列可证明为空时触发；长时间解码（数小时工具调用）保持 `active` ≥ 1 ，永远不会被探测。检查 D 要求工作在途且 token 计数器冻结——空闲服务器没有可冻结的引用。v2 设计（日志 `mtime`）违反了这一点：取消请求写入日志行，将死引擎标记为“忙碌”。

空注册表感知 (F4 修复)。模型切换后注册表可能暂时为空； $B(t)$ 将 $\emptyset$ 视为健康而非触发重启风暴 (v5 时代有 79 次此类事件)。

图 3 展示了单次心跳的决策流程。

5 恢复：有界升级阶梯

当 $H(t) = \text{FALSE}$ 时，看门狗升级：

1. `omlx restart --timeout 240` (引擎级，不杀进程)
2. 失败时: `PORTCLEAN` – 用 `lssof -sTCP:LISTEN` 在:8000 上识别 PID, `kill`, 30 秒宽限, 然后 `kill -9`; 重试步骤 1
3. 最后手段: `open -a oMLX` (GUI 重启)

PID 锁文件防止重入心跳。**PortClean 安全性**：kill 目标被验证为端口 8000 上的唯一 TCP 监听者——从不匹配进程列表——因此不可能向无关进程发送信号。阶梯是有界的：每次心跳最多一次重启、一次端口清理、一次 GUI 启动；下次心跳从干净状态重新评估。




图 2: 故障类别到恢复阶梯步骤的因果映射。F2（端口占用者）是唯一需要步骤 2 的类别；其余均由步骤 1 解决或通过版本化修复消除。

图 4 展示了带时间边界的阶梯。

6 评估：13 天生产数据

设置。Apple M5 Max, 128GB 统一内存；macOS Tahoe；oMLX v0.6.x 服务 Qwen3.8-27B（oQ8e，后 oQ4e）+ MTP；launchd StartInterval=60。客户端：DSH Web GUI、OpenClaw/Hermes 网关（同一端点）。

9 月 8 日窗口（F1 卡死 + F4 陈旧注册表，v6 前）展示了阶梯在高负载下的表现：96 次回退升级全部完成恢复，v4 端口清理修复消除了 F2 旋转。v6 之后（9 月 9 日），48h 内零误报重启。

吞吐量上下文。oQ4e + MTP（接受率 85–96%）+ TurboQuant Q4 KV 缓存下，短上下文解码达 ~30–50 tok/s；长上下文（80k+ token）稳定在 12–25 tok/s，与 M5 Max ~614 GB/s 内存带宽对权重 +KV 读取的约束一致。可用性（本文）与吞吐量正交：三层防御体系将二者相乘。

图 5 展示了 13 天跟踪的事件时间线。

7 相关工作

Kubernetes 存活/就绪探针假设有进程杀死权限的编排器；我们的阶梯是单主机类比，其中“编排器”（launchd）故意不自动重启 GUI 应用。SRE 自愈模式（有界升级、无重试放大）直接映射到阶梯步骤 1–3 和客户端侧 maxRetries=40 边界。本地 LLM 工具（Ollama、llama.cpp server）未提供等效看门狗；DFlash/MTP 投机解码改善每请求吞吐量但不解决部分可用性问题。

指标	数值
总心跳数 / 挂钟时间	18,516 / 13.2 天
HEALTHY 空闲心跳	13,527 (73.0%)
BUSY 心跳	4,188 (22.6%)
恢复事件完成	79 RECOVERED, 0 STILL_DOWN (阶梯后)
平均检测时间 (MTTD)	$\leq 60\text{ s}$ (一次心跳)
平均恢复时间 (MTTR)	$< 4\text{ min}$ (重启 + 重载观察)
误报重启 (v6 时代)	最后 48h 窗口内 0
解码吞吐量 (BUSY 心跳)	中位 1.9 tok/s; p90 7.6 tok/s (长上下文, TQKV+MTP)

表 2: 生产统计, `watchdog.log`, 2026-08-27 $\rightarrow$ 2026-09-09。

8 效度威胁

单一操作者、单台机器、一个服务器版本族。`loaded_models` 字段是稳定 API 表面但非契约性的；检查 B 在重命名时优雅降级（空注册表感知）。吞吐量数字是跟踪推导的中位数，非受控基准测试。

9 结论

一个 180 行 shell 脚本，四个非冲突谓词和一个有界阶梯，为无编排器的本地 LLM 服务器提供完整自愈： $\text{MTTD} \leq 60\text{s}$ 、 $\text{MTTR} < 4\text{min}$ ，13 天智能体工作负载零人工干预。该设计通过替换重启原语推广到任何 OpenAI 兼容本地后端（`llama.cpp`、`Ollama`）。

工件可用性

看门狗 + 安装器：<https://github.com/ricky8848/omlx-watchdog> (MIT, v6.1; `curl | bash`)。三层配置：<https://github.com/ricky8848/mac-m5-128g-omlx-settings>。完整去标识化跟踪：[docs/paper/production-](#) (在工件仓库中)。




图 3: 单次看门狗心跳的决策流程。每个检查仅在前序全部通过时评估；任何失败路由到有界升级阶梯 (第 5 节)。




图 4: 带时间边界的有界升级阶梯。每步每次心跳最多尝试一次；下次心跳从干净状态重新评估。




图 5: 13 天跟踪的事件时间线。9 月 8 日窗口 (F1+F4) 展示了阶梯在高负载下的表现；v6 之后零误报重启。